

Model napovedi odjema električne energije

Matematika z računalnikom 2023/24

Karolina Šavli

Maj 2024

1 Uvod

Cilj projektne naloge je sestaviti model, ki bo napovedal odjem električne energije za celotni naslenji dan (za naslednjih 24 ur).

Celotna analiza je izvedena v programskem jeziku Python.

2 Osnovna analiza časovne vrste

Podjetje GEN-I je v obliki excel razpredelnice pripravilo tabelo podatkov, sestavljeno iz sedmih stolpcev:

- `DateTimeStartUTC`: univerzalni koordinirani čas,
- `DateTimeStartCET`: srednjeevropski čas,
- `Odjem ACT`: neto odjem električne energije v kWh,
- `Temperatura ACT`: dejanska temperatura,
- `Temperatura FC`: napovedana temperatura,
- `Sevanje ACT`: dejansko sevanje in
- `Sevanje FC`: napovedano sevanje.

Slika 1: Tabela podatkov, 2021-2024


	<code>DateTimeStartUTC</code>	<code>DateTimeStartCET</code>	<code>Odjem ACT</code>	<code>Temperatura ACT</code>	<code>Temperatura FC</code>	<code>Sevanje ACT</code>	<code>Sevanje FC</code>
0	31.10.2021 23:00	2021-01-11 00:00:00	0.000010	3.60	5.300	0.0	0.0
1	31.10.2021 23:15	2021-01-11 00:15:00	0.000009	3.60	5.300	0.0	0.0
2	31.10.2021 23:30	2021-01-11 00:30:00	0.000009	3.60	5.300	0.0	0.0
3	31.10.2021 23:45	2021-01-11 00:45:00	0.000009	3.60	5.300	0.0	0.0
4	1.11.2021 00:00	2021-01-11 01:00:00	0.000008	3.45	5.300	0.0	0.0
...
80059	12.02.2024 21:45	2024-12-02 22:45:00	0.000012	8.00	3.375	0.0	0.0
80060	12.02.2024 22:00	2024-12-02 23:00:00	0.000012	7.90	3.200	0.0	0.0
80061	12.02.2024 22:15	2024-12-02 23:15:00	0.000011	7.80	3.300	0.0	0.0
80062	12.02.2024 22:30	2024-12-02 23:30:00	0.000011	7.15	3.400	0.0	0.0
80063	12.02.2024 22:45	2024-12-02 23:45:00	0.000009	6.50	3.500	0.0	0.0

V analizi sem uporabljala vse stolpce, razen stolpca `DateTimeStartUTC`, saj je v okviru časa bolj relevanten stolpec `DateTimeStartCET`. Podatki so podani za odboje od 1. novembra 2021 do 12. februarja 2024, na vsakih 15 minut. Tabela ima torej vsega skupaj 80064 vrstic.

2.1 Odjem električne energije

Slika 2 prikazuje odjem električne energije za obdobje od 1. novembra 2021 do 12. februarja 2024. Opazna je sezonskost; odjem je znatno večji jeseni in pozimi, zaradi povečane uporabe energije za ogrevanje in razsvetljevo, saj se število ur dnevne svetlobe podaljša.

Slika 2: Odjem električne energije, 2021-2024




S Tabele 1 preberemo, da je povprečna poraba električne energije gospodinjskih odjemalcev okrog 12240,53 MWh, minimalna dosežena vrednost je 3629,32 MWh, maksimalna pa 28736,80 MWh. Vrednosti varirajo okrog 4167,98 MWh.

Tabela 1: Opisne statistike porabe električne energije, 2021-2024

	Min	Max	Povprečje	Mediana	Standardni odklon
Odjem [MWh]	3629,32	28736,80	12240,53	11708,50	4167,98

Odjem električne energije je med tednom najmanjši ponoči in se veča do viška okrog 18 ure. V soboto in nedeljo pa je prvi višek porabe dopoldne, drugi pa okrog 18 ure, kar je opazno s Slike 3, ki prikazuje odjem električne energije v drugem tednu septembra 2023. Imamo torej tudi sezonskost na dnevni ravni.

Slika 3: Odjem električne energije po urah, drugi teden septembra 2023




Zaključimo lahko, da je naša časovna vrsta visokofrekvenčna, ima sezonsko komponentno ter njeno povprečje ni konstantno.

2.2 Povezava med odjemom in temperaturo ter sevanjem

Na odjem električne energije ključno vpliva del leta in s tem temperature, kar je razvidno tudi iz Slike 4. Povezave med sevanjem in odjemom s Slike 4 ni opaziti; sklep da zato, ker ne analiziramo samooskrbnih odjemalcev (tisti ki imajo svojo sončno elektrarno).

Slika 4: Povezava med odjemom in temperaturo ter sevanjem, 2021-2024



V nadaljevanju bomo v upanju boljše napovedi v naše modele vključili tudi temperaturo in sevanje, kot eksogeni spremenljivki.

3 Napredna analiza in izbira modela

3.1 Izbira družine modelov


ARIMA je model, ki pri napovedovanju zajame vzorce, trende in sezonskost podatkov s kombinacijo preteklih vrednosti, razlik in napak. Ker pa imamo v podatkih očitno sezonskost, lahko ARIMO nadgradimo v SARIMO, ki dodatno upošteva še sezonske vzorce. Ta družina modelov ima težavo predvsem pri napovedih, ko ima časovna vrsta skozi čas spremembo variance. Da bo naše napovedovanje bolj učinkovito, bomo naš SARIMA nadgradili v model SARIMA-GARCH, saj se model GARCH uporablja ravno za modeliranje združevanja volatilnosti v podatke časovnih vrst. [1]

3.2 Odstranitev sezonskosti in pridobitev stacionarnosti

Da bomo lahko indentificiralni potencialne modele, moramo najprej originalno časovno vrsto (Slika 2) narediti stacionarno.


Ker so naši podatki volatilni najprej naredimo **logaritmične donose** (ang. *log returns*). Če z W_t označimo originalno časovno vrsto odjema električne energije, so logaritmični donosi definirani kot časovna vrsta $Y_t = \ln\left(\frac{W_t}{W_{t-1}}\right)$. Slednja časovna vrsta je prikazana na Slika 5.

Slika 5: Logaritmični donosi odjema električne energije, 2021-2024




Slika 6 prikazuje ACF (vzorčno avtokorelacijo) in PACF (vzorčna parcialna avtokorelacija) logaritmičnih donosov do odloga 1000 (to je malo manj kot dva tedna). Z grafov je očitno, da časovna vrsta ni stacionarna. Opazna je sezonska komponentna, in sicer 96, kar je ravno en dan ¹.

Slika 6: Vzorčna avtokorelacijska in parcialna avtokorelacija funkcija časovne vrste logaritmičnih donosov




Da dosežemo stacionarnost, se je potrebno sezonskosti znebiti, zato bomo podatke **sezonsko diferencirali**. Nova časovna vrsta bo $Z_t = Y_t - Y_{t-96}$. Prikazana je na Slika 7, njeni ACF in PACF pa na Slika 8.

Slika 7: Časovna vrsta po sezonskem diferenciranju, 2021-2024



Slika 8: Vzorčna avtokorelacijska in parcialna avtokorelacija funkcija časovne vrste po sezonskem diferenciranju




Na grafu ACF opazimo ponavljanje vzorca, kar pomeni, da časovna vrsta Z_t še kar ni stacionarna. Še


¹Podatki so podani na 15 minut in $15 \text{ min} \cdot 96 = 1440 \text{ min}$, kar je ravno en dan.

enkrat jo diferenciramo in dobimo vrsto $X_t = Z_t - Z_{t-1}$. Prikazana je na Slika 9, njeni ACF in PACF pa na Slika 10.

Slika 9: Časovna vrsta po prvem nesezonskem diferenciranju, 2021-2024



Slika 10: Vzorčna avtokorelacijska in parcialna avtokorelacijska funkcija časovne vrste po prvem nesezonskem diferenciranju



Dobljena časovna vrsta X_t zglada stacionarno in tudi formalni testi Augmented Dickey-Fuller (ADF), KPSS in Phillips-Perron potrdijo njeno stacionarnost. Časovna vrsta je torej primerna za izbero parametrov modela SARIMA.

3.3 Identifikacija modela SARIMA

Na podlagi ACF in PACF (Slika 10) stacionarne časovne vrste X_t izberimo parametre modela SARIMA(p, d, q)(P, D, Q)[S]. Kaj sploh predstavljajo ti parametri? Razdelimo jih lahko v dve skupini, in sicer v skupino nesezonskih (p, d, q) in sezonskih (P, D, Q, S) [2]:


- $p \dots$
- $d \dots$
- $q \dots$
- $P \dots$
- $D \dots$
- $Q \dots$
- $S \dots$

Ker smo časovno vrsto enkrat sezonsko diferencirali bo $D = 1$ in ker smo jo enkrat navadno diferencirali bo $d = 1$. Perioda je enaka 96, torej je $S = 96$.

Za določitev sezonskih parametrov P in Q gledamo korelacije pri odlogih, ki so večkratniki periode S . Pri PACF visoko korelacijo opazimo predvsem pri 96 in 192, nato pa se z vsako dodatno periodo manjša. Parameter P je torej 1 ali več; predlagala bi 1, 2 ali 3. Pri ACF pa je občutna korelacija zgolj pri 96, zato vzamemo $Q = 1$.

Za lažjo določitev nesezonskih parametrov p in q bomo gledali ACF in PACF do prve periode (torej do odloga 96). Slednje je prikazano na Slika 11. Tako iz PACF, kot tudi iz ACF, je opazna večja korelacija pri prvih nekaj urah in v uri tik pred periodo. V modelu bomo zato zagotovo vključili prvih nekaj ur, saj le-te kažejo močan vpliv.

Slika 11: Vzorčna avtokorelacijska in parcialna avtokorelacijska funkcija časovne vrste po prvem nesezonskem diferenciranju, odlogi do 100



Izbrala sem nekaj potencialnih modelov SARIMA, kjer sem kot eksogeno spremenljivko podala temperaturo in sevanje. Modele sem trenirala na 75 % podatkov, to je od 1. novembra 2021 do 4. avgusta 2023. Na preostanku podatkov pa sem testirala napovedi. Vrednosti kriterija AIC za posamezne modele so prikazane v Tabeli 2. Najmanjšo vrednostjo kriterija AIC ima model SARIMA(4, 1, 5)(0, 1, 0)[96].

S Tabele 2 je razvidno, da sem za sezonska parametra P in Q v vseh primerih izbrala vrednost 0, čeprav sklepam, da bi bile bolj optimalne višje vrednosti. Te modele sem poskusila zagnati, vendar moj računalnik ni vrnil nobenega rezultata, ker očitno ni dovolj zmogljiv.

Tabela 2: Vrednost kriterija AIC za izbrane modele iz družine SARIMA

Model	AIC
SARIMA(1,1,0)(0,1,0)[96]	-338588,046
SARIMA(0,1,1)(0,1,0)[96]	-346718,519
SARIMA(1,1,1)(0,1,0)[96]	-346768,583
SARIMA(2,1,1)(0,1,0)[96]	-347555,507
SARIMA(3,1,2)(0,1,0)[96]	-347573,394
SARIMA(4,1,3)(0,1,0)[96]	-278981,698
SARIMA(5,1,4)(0,1,0)[96]	-345287,413
SARIMA(5,1,5)(0,1,0)[96]	-345310,105
SARIMA(4,1,5)(0,1,0)[96]	-347619,304
SARIMA(6,1,5)(0,1,0)[96]	-345325,842
SARIMA(6,1,6)(0,1,0)[96]	-345342,972
SARIMA(5,1,6)(0,1,0)[96]	-345351,794

Izbran imamo model SARIMA, v naslednjem koraku pa na podoben način izberimo še model GARCH.

3.4 Izbira modela SARIMA-GARCH

Model GARCH(p, q) bomo konstruirali na rezidualih izbranega modela SARIMA. Preizkusili bomo 6 kombinacij parametrov p in q, in sicer (1, 1), (1, 2), (2, 1), (2, 2), (1, 3) ter (3, 1). Izbrali bomo model na podlagi vrednosti kriterija AIC.

Tabela 3: Vrednost kriterija AIC za izbrane modele SARIMA(4, 1, 5)(0, 1, 0)[96]-GARCH(p, q)

SARIMA-GARCH(p,q)	AIC
(0, 0)	-347619,304
(1, 1)	-365754,448
(1, 2)	-366056,218
(2, 1)	-365434,577
(2, 2)	-365843,673
(1, 3)	-366134,335
(3, 1)	-365252,576

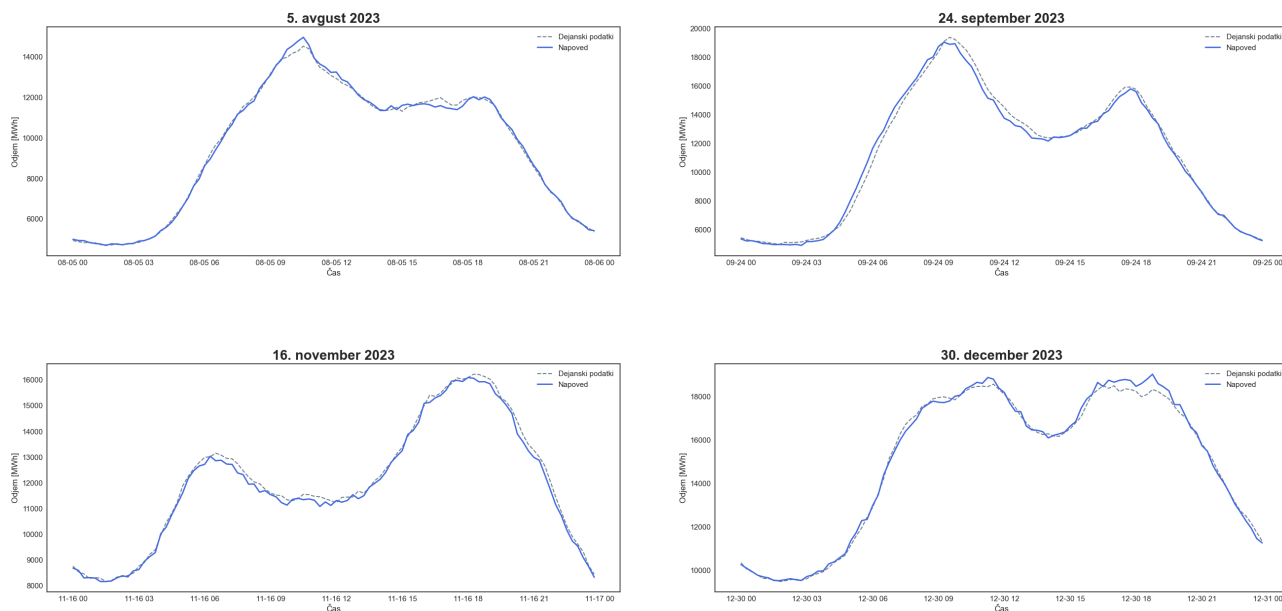
Na podlagi vrednosti kriterija AIC se odločimo za model SARIMA(4, 1, 5)(0, 1, 0)[96]-GARCH(1, 3), saj je iz Tabele 3 razvidno, da ima najmanjši AIC.

3.5 Izbran model

Na podlagi vrednosti kriterija AIC se odločimo za model SARIMA(4, 1, 5)(0, 1, 0)[96]-GARCH(1, 3). V matematičnem jeziku je oblike:

4 Testiranje izbranega modela

Slika 12: Napovedi odjema električne energije za izbrane datume



5 Zaključek




Tabela 4: Vrednost napake RMSE in MAPE za izbrane datume

Datum	RMSE	MAPE
5.avg.23	156,600	1,104
24.sep.23	365,372	2,392
16.nov.23	176,901	1,199
30.dec.23	224,123	1,046
7.jan.23	399,578	1,839
12.feb.23	248,981	1,287
Povprečje	261,926	1,478

Literatura

- [1] T. Dierckx. ARIMA-GARCH forecasting with Python. *Medium*, Sept. 2020.
- [2] B. Köseoğlu. Guide to Time Series Analysis with Python — 4: ARIMA and SARIMA. *Medium*, Jan. 2024.